

UNIVERSIDAD DEL VALLE DE GUATEMALA

Minería de datos, sección 30



Investigación de algoritmos

Proyecto 3

Sofia Garcia – 22210
Julio Garcia Salas – 22076
Sebastian Garcia – 22291
Jose Angel Morales – 22689

GUATEMALA, mayo de 2025

Variable Respuesta: tipo_medida

Problema a resolver:

¿Es posible predecir el tipo de medida judicial que se impondrá a una persona denunciada por violencia intrafamiliar utilizando únicamente los datos administrativos de la denuncia? Resolver esta pregunta implica identificar cuáles variables sociodemográficas, contextuales e institucionales tienen mayor capacidad explicativa sobre la decisión judicial, y determinar si esta información aporta señal suficiente para construir un modelo predictivo robusto y generalizable.

Partición de conjuntos antes del entrenamiento:

El conjunto de datos original constó de 328 959 observaciones y 85 variables, de las cuales se creó la variable respuesta categórica `target_grouped` agrupando las clases con menos de 100 muestras en una categoría “Other” adicional. Para la partición en entrenamiento y prueba se aplicó un muestreo estratificado al 80 % / 20 %, obteniéndose 263 167 registros para entrenamiento y 65 792 para prueba. Dado el marcado desequilibrio – la clase “NoMeasure” representó aproximadamente el 49 % del total y la segunda clase más frecuente (“I”) un 37 %– no se aplicó oversampling o undersampling tradicional. En su lugar se computaron pesos inverso–frecuencia por clase para entrenar los modelos, de modo que cada observación aportara proporcionalmente a la contribución de su categoría minoritaria sin descartar datos ni generar nuevas muestras.


Análisis de algoritmos a utilizar:**SVM:**

Se realizó el algoritmo de SVM, no obstante, el algoritmo pasó mucho tiempo trabajando y nunca terminó de completarse. Por lo tanto, se descartará SVM por problemas de rendimiento.


HistGradientBoostingClassifier

El HGB con 120 iteraciones, learning rate 0.05 y 31 hojas máximas (configuración 2) alcanzó un 70 % de precisión global, con un recall promedio ponderado de 0.70 y un recall macro de 0.55. La matriz de confusión muestra una alta tasa de aciertos para las dos clases dominantes (“NoMeasure” e “I”), mientras que las clases menos frecuentes presentan recall entre 0.45 y 0.79 según la clase, reflejando que el uso de pesos mejoró sustancialmente la detección de minoritarias.


Matriz de confusión Modelo #1 HGB



Matriz de confusión Modelo #2 HGB



Matriz de confusión Modelo #3 HGB



A partir de la primera configuración (Conf1: 80 iteraciones, $\text{learning_rate}=0.1$, $\text{max_depth}=4$) se observa que, aunque la diagonal principal muestra un bloque claro para las dos clases dominantes (“I” y “NoMeasure”), existen dispersos errores sobre todo en las clases intermedias y minoritarias. Por ejemplo, solo el 34 % de las “A” se clasifica correctamente (2 262 de 6 677), mientras un 26 % se confunde con “C” (849 casos). La clase “I” alcanza un recall cercano al 33 % (8 123/24 477), y “NoMeasure” sube al 97 % (31 516/32 439), lo cual explica el 67 % de accuracy global. Sin embargo, la macro-recall (0.54) indica que muchas clases pequeñas (p. ej. “D”, “H”, “Other”) siguen teniéndolo difícil para llegar al 50 %.


La segunda configuración (Conf2: 120 iteraciones, $\text{learning_rate}=0.05$, $\text{max_leaf_nodes}=31$) reduce notablemente los errores en las clases medias: la clasificación de “A” crece al 41 % (2 416 aciertos), y “I” mejora a un 42 % (10 162/24 477). Las clases “B”, “C” y “F” también presentan aumentos de recall (p. ej. “C” sube de 40 % a 43 %). La diagonal se estrecha y el ruido fuera de ella disminuye, especialmente en etiquetas que antes se confundían con “C” o “I”. Esto impulsa la accuracy global al 70 % y el F1-weighted al 0.75. La mejora se produce a costa de un mayor tiempo de entrenamiento, pero logra un mejor balance entre precisión y recall para la mayoría de las clases.

En la tercera configuración (Conf3: 100 iteraciones, learning_rate=0.2, max_depth=6) se conserva el avance en las clases dominantes: “A” alcanza ahora un 41 % de recall (2 454 aciertos), mientras “I” sube ligeramente al 41 % de acierto con 9 946 predicciones correctas. Los falsos positivos para “C” y “I” se decrementan frente a Conf1, y la diagonal de “NoMeasure” sigue sólida, con un 98 % de recall. La accuracy global está nuevamente en torno al 70 %, y el F1-weighted baja muy ligeramente a 0.74. En suma, Conf2 ofrece el mejor compromiso: mayores aciertos para clases medias sin degradar la clasificación de las dominantes, mientras Conf3 muestra una ganancia marginal que puede no justificar la tasa de entrenamiento.


Gradient Boosting Classifier

El XGBoost mostró un mejor desempeño en su primera configuración (eta = 0.1, max_depth = 6, subsample = 0.8), alcanzando un 73 % de precisión y un F1 ponderado de 0.77. El recall macro se mantuvo en torno a 0.55, con un notable incremento del recall en clases intermedias (por ejemplo, clase “C” alcanzó 0.80). La combinación de submuestreo interno (subsample y colsample_bytree) junto con early stopping permitió reducir ligeramente el overfitting observado en HGB y ganar robustez en las clases medias.


Matriz de confusión Modelo #1 XGBoost



Matriz de confusión Modelo #2 XGBoost



Matriz de confusión Modelo #3 XGBoost



La primera configuración ofrece un compromiso intermedio: “NoMeasure” mantiene un sólido 98 % de recall, “A” y “I” alcanzan ambos un 47 % (~2 766/5 921 y 11 559/24 477, respectivamente), mientras “C” se queda en 45 %. El resto de clases medias mejora frente a la configuración 2 pero sin llegar a los picos de la 3. La accuracy global ronda el 73 % y el macro-recall se mantiene cerca de 0.55. Con un tiempo de entrenamiento moderado (~53 s), esta opción resulta adecuada cuando se busca un balance razonable entre rendimiento en clases dominantes y complejidad de modelo.


La matriz de la segunda configuración muestra una diagonal claramente visible para las clases dominantes “NoMeasure” (31 129/32 439 → 96 % de recall) e “I” (6 969/24 477 → 28 %), pero un rendimiento moderado en el resto. Por ejemplo, sólo un 34 % de las “A” (2 026/5 921) y un 39 % de las “C” (1 017/1 467) son correctamente identificadas, mientras que clases muy minoritarias como “D”, “H” u “Other” apenas superan el 20–30 % de recall. En conjunto, esto se traduce en una accuracy global de ~64 % y un macro-recall en torno al 0.54: buena identificación de la etiqueta mayoritaria, pero bajo poder discriminativo para las clases menos frecuentes.

Al aumentar la profundidad a 8 y la tasa de aprendizaje a 0.2, la diagonal principal se refuerza notablemente. “T” sube hasta un 68 % de recall (16 638/24 477), “A” alcanza el 55 % (3 261/5 921) y “C” el 53 % (1 129/1 467). Las clases intermedias también mejoran: “B” pasa a un 63 % de recall, “J” a 62 %, y “NoMeasure” logra un 98 %. Esto eleva la accuracy global a ~82 % y el weighted-F1 a 0.83. La complejidad extra (depth=8) y el mayor coste de entrenamiento (~58 s) quedan justificados por la ganancia en recall y F1 especialmente en clases que antes quedaban relegadas.


Catboost

CatBoost presentó dificultades para clasificar múltiples clases debido a la escasez de datos en las categorías más pequeñas, mostrando prácticamente recall cero en varias de ellas y un F1 global insignificante. Esto sugiere que, pese a sus buenos resultados en problemas balanceados, requiere un mínimo de representatividad para cada categoría o un tratamiento distinto (por ej. reclasificación de clases muy escasas).


Matriz de Confusión Modelo #1 Catboost



Matriz de Confusión Modelo #2 Catboost



Matriz de Confusión Modelo #3 Catboost



En la primera matriz de CatBoost, la clase mayoritaria “NoMeasure” alcanza un recall moderado (~62 %: 11 732/18 966), mientras que “I” obtiene un 26 % (6 403/24 477). Las clases intermedias mejor muestran su desempeño en “E” (53 % de recall, 4 901/9 250) y “D” (20 %, 649/3 168), pero caen drásticamente en etiquetas muy minoritarias como “A”, “B” o “H” (<10 %). Este modelo resulta pobre detectando la mayoría de categorías salvo unas pocas, con un weighted-F1 en torno a 0.20 y un sesgo hacia la clase mayoritaria que limita su utilidad en un problema multiclase tan heterogéneo.

Al reducir el learning rate y aumentar la profundidad, “NoMeasure” mejora a un recall cercano al 70 % (11 206/16 000), y “I” sube al 26 % (6 233/24 477). Destacan “E” (43 %) y “D” (21 %), mientras que “A” y “C” se mantienen en torno al 1 %–5 % debido a su baja representación y a que el modelo prefiere las clases mayores. El macro-recall global apenas supera 0.25. Aunque la configuración 2 corrige algo el sesgo hacia “NoMeasure”, sigue sin resolver el desequilibrio y exige un coste de hasta 358 s de entrenamiento.


Con menos iteraciones y mayor tasa de aprendizaje, se observa una ligera mejora en “NoMeasure” (60 %, 10 559/17 632) y “I” (25 %, 6 131/24 477), además de un aumento en “E” (55 %, 5 488/9 950). Sin embargo, la profundidad reducida penaliza de nuevo a las minoritarias (“A”: ~0 %, “B”: <1 %). La accuracy global ronda el 24 %, similar a las anteriores, pero con un entrenamiento mucho más rápido (~41 s). Esta última configuración podría servir

cuando el tiempo de cómputo es crítico, sacrificando la detección de clases escasas en favor de la eficiencia.

Arboles de Decisión


El modelo de árboles de decisión no mostro ser muy efectivo a la hora de clasificar las distintas clases del problema mostrando un gran desbalanceo. Para las 3 configuraciones distintas que se utilizaron se mostró que habia un sesgo con respecto a la clase I en la cual salvo la clase ‘No Measure’ todas las clases se predijeron erróneamente a esta clase. El mejor de estos modelos el cual logro disminuir las predicciones erroneas para la clase I fue en el que no se limitó la profundidad del modelo alcanzando una precisión global de apenas un 33%, con un recall del 29%. Este redujo un número decente de los errores de predicción hacia la clase I mejorando la precisión con respecto al primer modelo de 13% en el cual se estableció la profundidad máxima como 5, mas no logro deshacerse del sesgo hacia la clase I.

Matriz de Confusión Modelo #1 Arboles de decision




Modelo 1

El primer modelo es en el que más se puede apreciar este sesgo siendo que salvo para la medida ‘No Measure’, todas las clases fueron clasificadas erróneamente en la clase I. Este modelo cuya profundidad máxima se estableció en 5 apenas llego a un 13% de precisión global con un 15% de recall. El sesgo para la medida ‘No Measure’ fue bastante menor siendo que solo se predijeron 1499 erróneamente como la clase I mientras que el resto de 30940 se predijeron de forma correcta y para la clase I todas se predijeron de manera correcta.



Modelo 2

Para el segundo modelo se aumentó la profundidad máxima de 5 a 10, esto logro un aumento ligero en la precisión para todas las clases dado a que ya no se predicen todas como la clase I. La precisión global para este modelo fue de 21% indicando un 8% de mejora con respecto al primer modelo mientras que con un recall de 16% este solo aumento 1% con respecto al modelo anterior. El aumento de profundidad castigo principalmente a la clase I siendo que esta ahora consta con errores de predicción hacia las clases A, C y ‘No Measure’; mientras que esta última aumento ligeramente su precisión prediciendo correctamente 31446 casos comparado a los 30940 del modelo anterior.




Modelo 3

El tercer modelo en el que no se establecieron límites para la profundidad mostro ser el mejor de los 3 aumentando la precisión global a un 33% y el recall a un 29%. Siendo un aumento con respecto al modelo anterior de 12% y 13% respectivamente. La falta de límites de profundidad castigo principalmente a la clase I la cual ahora cuenta con errores de predicción en todas las clases mayoritariamente en la clase A, mientras que esto a su vez logro un aumento considerable en la precisión del resto de clases. A pesar de ello todavía se puede apreciar cierto sesgo hacia la clase I siendo que la mayoría de los errores para todas las clases se ven concentrados en la clase I.


Bayes Ingenuo

La familia de modelos GaussianNB mostró un rendimiento muy limitado en este problema de clasificación multiclase y desbalanceado. Bajo la configuración por defecto ($\text{var_smoothing}=1\text{e-}9$), el modelo alcanzó un accuracy global moderado de aproximadamente 47 %, pero su macro-recall quedó en torno al 23 %, reflejando que, salvo para la clase “D” ($\text{recall} \approx 89 \%$), casi todas las clases minoritarias fueron prácticamente inapropiadamente ignoradas. Al incrementar el parámetro de suavizado a $1\text{e-}8$ y $1\text{e-}7$, el accuracy se desplomó ($\approx 10 \%$ y $\approx 3 \%$ respectivamente) y el macro-recall apenas mejoró, mientras que el modelo tendió a predecir de forma aún más masiva la etiqueta mayoritaria “NoMeasure”. En conjunto, GaussianNB resulta insuficiente para capturar los patrones de las clases menos frecuentes en este conjunto de datos, siendo superado por el fuerte desequilibrio y la complejidad de las características.


Matriz de Confusión Modelo #1 Naive Bayes



Matriz de Confusión Modelo #2 Naive Bayes



Matriz de Confusión Modelo #3 Naive Bayes



Modelo #1

El modelo tiende a colapsar casi todas las predicciones sobre unas pocas etiquetas dominantes. Por ejemplo, para la clase “D” (38 muestras) consigue un recall muy alto (34 de 38 correctamente etiquetadas) gracias a que predice “D” masivamente; sin embargo, para las demás clases pequeñas (A, B, C, E, F, G, H, J, L, Other) el recall es prácticamente cero, ya que la mayoría de sus ejemplos son clasificados erróneamente como “D” (por ejemplo, 4 456 de 5 921 filas de la clase A acaban predichas como D). La única excepción parcial es la clase “I”, donde consigue precisión alta (0.89) pero recall casi nulo (0.02), pues apenas identifica sus 822 verdaderos positivos frente a los 17 978 de la fila “I” que son desviados a “D”. En conjunto el accuracy global (~0.47) refleja el dominio de la clase mayoritaria “I” y “NoMeasure”, pero con un desempeño prácticamente nulo para todas las demás categorías.

Modelo #2

Al aumentar suavizado, el modelo incrementa ligeramente la diversidad de predicciones, reparte unos pocos ejemplos hacia “NoMeasure” y “Other” y eleva algo el recall de clases intermedias. No obstante, persiste la gran caída de recall fuera de “D”: la fila D se mantiene con 33 de 38 aciertos, mientras que clases como A, B o C siguen siendo predichas casi siempre como “D” (4 125 de 5 921 A; 379 de 678 B; 1 138 de 1 467 C). Aparecen ligeros desplazamientos de “NoMeasure” desde la diagonal hacia “F” y “G”, pero las métricas macro

siguen muy bajas (macro-recall ≈ 0.18). El accuracy global se reduce drásticamente (~ 0.10) porque el modelo ha aprendido a predecir “D” aún más a menudo, sacrificando cualquier capacidad de distinguir clases menores.

Modelo #3


Con suavizado aún mayor se observa un efecto de “congelamiento”: el modelo concentra casi todo su poder predictivo en dos etiquetas (“D” y “G”), asignando la mayoría de clases a “D” (14 944 de 24 477 I; 3 785 de 5 921 A) o desplazando muchas muestras hacia “G” (por ejemplo, 1 627 de 5 921 A). La fila D retiene un recall aceptable (29/38), pero para el resto las tasas de recuperación se sitúan en 0.00–0.06. Además, la clase mayoritaria “NoMeasure” ve cómo más de la mitad de sus 32 439 ejemplos se van a “D” (23 827) y solo 6 103 quedan en su etiqueta real. El accuracy se hunde aún más (~ 0.03), confirmando que, a pesar de ajustes de suavizado, GaussianNB no logra distribuir predicciones de manera razonable en un problema multiclase tan desbalanceado.

Random Forest


En conjunto, los tres Random Forest ajustados muestran cómo distintos compromisos de profundidad, número de árboles y selección de características afectan la recuperación (“recall”) de las clases minoritarias sin desplomar demasiado la precisión global. El RF1 (300 árboles, profundidad ilimitada, $\sqrt{\text{features}}$) maximiza la exactitud global (0.86) atendiendo la gran mayoría de la clase “I” y “NoMeasure” (recall $\approx 0.99/0.96$), pero casi ignora las clases menos frecuentes (recall medio por debajo de 0.14 en todas las demás), lo que se traduce en un macro-recall muy bajo (≈ 0.24).

Al limitar la profundidad a 20, reducir hojas y usar $\log_2(\text{features})$ en el RF2, la exactitud apenas baja a 0.85, mientras que el recall medio por clase sube a ≈ 0.37 : ahora las clases B, C, F, G y J ganan terreno (recall entre 0.15 y 0.55) y el macro-f1 mejora a 0.37. El RF3, con 200 árboles, profundidad 15 y 70 % de features en cada árbol, sacrifica algo más de exactitud (0.79) para lograr el mayor balance: su macro-recall se eleva a ≈ 0.51 y el macro-f1 a 0.35, alcanzando recuperaciones superiores al 0.40 en la mayoría de las categorías intermedias (por ejemplo, recall 0.79 en “C”, 0.67 en “B” y 0.71 en “A”), lo que demuestra que una configuración moderada de complejidad puede repartir mejor la capacidad predictiva entre clases frecuentes y raras.


Matriz de Confusión Modelo #1 RF



Matriz de Confusión Modelo #2 RF



Matriz de Confusión Modelo #3 RF



RF Tuned 1 muestra una matriz muy sesgada hacia las clases mayoritarias “I” y “NoMeasure”: casi todos los ejemplos de estas categorías (24 444 de 24 477 y 31 117 de 32 439, respectivamente) se clasifican correctamente, pero las demás clases quedan casi invisibles. Por ejemplo, de los 5 921 casos de “A” apenas acierta 713, y los 1 467 de “C” sólo 387 pasan al verdadero positivo. Las clases intermedias (B, F, G, J, etc.) aparecen con recuentos de TP inferiores a 100–200, lo que confirma el alto accuracy global (0.86) a costa de un recall nulo o muy bajo en la mayoría de categorías minoritarias.


RF Tuned 2, al recortar profundidad a 20 y ajustar min_samples_leaf=2, reparte mejor la previsión entre clases. Sigue excelente en “I” (22 348/24 477) y “NoMeasure” (30 711/32 439), pero aumenta notablemente los verdaderos positivos en “A” (1 584 vs. 713) y “C” (805 vs. 387), y mantiene un TP decente en B (256) y F (227). Aunque pierde algo de exactitud global (0.85), mejora el recall promedio de las clases menos frecuentes, reduciendo el sesgo hacia las dos categorías mayores.

RF Tuned 3, con 200 árboles, profundidad 15 y max_features=0.7, hace el mayor esfuerzo por recuperar todas las etiquetas. Si bien disminuye la exactitud a 0.79 y baja el acierto en “I” (17 427/24 477) y “NoMeasure” (30 683/32 439), duplica o triplica los verdaderos positivos en muchas clases minoritarias: “B” pasa de 97→456, “C” de 387→1 166, “F” de 14→160 y “G” de 1→75, entre otros. Este reparto más equitativo evidencia cómo una configuración más moderada sacrifica algo de precisión global para elevar considerablemente el recall de las categorías menos representadas.


KNN

En esta etapa del estudio se entrenaron y evaluaron tres configuraciones del algoritmo K-Nearest Neighbors (KNN), con el fin de clasificar medidas de ocupación en un conjunto de datos altamente desbalanceado. Las clases mayoritarias, como “I”, “Other” y “NoMeasure”, dominan el total de observaciones, dificultando la predicción precisa de las clases menos representadas. Para mitigar la complejidad del modelo, se aplicó una reducción de dimensionalidad de 69 a 5 variables principales. A pesar de esta optimización, el desbalance de clases siguió influyendo notablemente en el desempeño de los modelos.


Matriz de Confusión Modelo #1 KNN



Matriz de Confusión Modelo #2 KNN



Matriz de Confusión Modelo #3 KNN



El primer modelo, KNN Optimizado, configurado mediante búsqueda en malla, alcanzó un accuracy de 0.66 y un weighted F1-score de 0.64, con un tiempo de entrenamiento eficiente (9.8 segundos). Sin embargo, mostró una fuerte inclinación hacia las clases mayoritarias, particularmente “I” (16 150 verdaderos positivos de 24 477) y “Other” (25 519 de 32 439). Si bien esto eleva el rendimiento global, sacrifica significativamente la recuperación de clases minoritarias. Por ejemplo, “A” solo obtuvo 1 041 verdaderos positivos de 5 921, “C” apenas 361 de 1 467, y clases intermedias como “B”, “F” y “G” presentaron recuentos muy bajos (70, 148 y 95 respectivamente). Muchas categorías tienden a ser clasificadas erróneamente como “Other”, lo que evidencia un sesgo estructural del modelo. El macro F1-score de 0.22 refleja esta falta de equidad en la clasificación entre etiquetas.

El segundo modelo, KNN Robusto, configurado para una mayor estabilidad mediante el uso del algoritmo ball_tree y un mayor número de vecinos, obtuvo una ligera mejora en el accuracy (0.67) y en el weighted F1-score (0.65), aunque con un tiempo de entrenamiento significativamente mayor (146.3 segundos). Este modelo también fue más equilibrado en su

comportamiento. Las clases dominantes “I” y “Other” mantuvieron altos niveles de aciertos (16 364/24 477 y 26 021/32 439 respectivamente), pero también se observaron mejoras modestas en clases menos frecuentes: “A” subió a 954 TP, “C” a 356 y “F” a 159. Incluso clases como “E” (30 vs. 25) y “L” (5 vs. 3) mostraron avances. Además, se redujeron las confusiones con “Other”, lo cual sugiere que este modelo maneja mejor los casos ambiguos. Aunque aún no logra una cobertura adecuada en todas las clases, representa un mejor balance entre exactitud y cobertura.

El tercer modelo, KNN Precisión, adoptó una configuración más liviana (algoritmo `kd_tree`, pesos uniformes y menor cantidad de vecinos) y presentó un accuracy levemente inferior (0.64) y un weighted F1-score de 0.63. No obstante, logró ciertos avances relevantes. Si bien “Other” bajó a 24 147/32 439 y “I” se mantuvo relativamente alto (16 226/24 477), se observaron mejoras interesantes en clases menos representadas: “A” alcanzó 1 128 TP, “F” subió a 165, y “NoMeasure” logró 6 733 aciertos, el valor más alto entre los tres modelos. Clases como “B”, “E” y “G” también mostraron un desempeño más estable. Este modelo parece haber priorizado la precisión en general, manteniendo una cobertura más razonable en las clases minoritarias sin comprometer drásticamente el rendimiento en las etiquetas dominantes.

Algoritmos a utilizar:

1. XGBoost (Gradient Boosting)

- a. **Rendimiento:** Con la configuración óptima (`eta=0.2`, `max_depth=8`, `subsample=0.9`, `colsample_bytree=0.9`) alcanzó un **82 %** de accuracy, un F1 ponderado de **0.83** y un macro-recall cercano a **0.47–0.55**.
- b. **Por qué profundizar:** además de mantener sólidas las clases dominantes (“I” y “NoMeasure” > 95 % de recall), fue el modelo que más elevó el recall en categorías intermedias (“A” 55 %, “C” 53 %, “B” 63 %, “J” 62 %) a costa de un coste de entrenamiento moderado (~ 58 s). Ajustar regularización (`lambda`, `alpha`), `scale_pos_weight` y estrategias de subsampling por clase puede empujar aún más su capacidad discriminativa.

2. HistGradientBoostingClassifier (Scikit-Learn)

- a. **Rendimiento:** Con 120 iteraciones, `learning_rate=0.05` y `max_leaf_nodes=31` obtuvo 70 % de accuracy, un recall ponderado de 0.70 y un macro-recall de 0.55, el más alto entre todos los métodos probados.
- b. **Por qué profundizar:** equilibró mejor la detección de las clases medias y pequeñas sin sacrificar las dominantes y con un tiempo de entrenamiento razonable (~ 39 s). Variar `l2_regularization`, `max_bins` y `min_samples_leaf` puede reducir el sesgo y mejorar la generalización.

3. RandomForestClassifier (con tuning para recall)

- a. **Rendimiento:** Su configuración más balanceada (200 árboles, profundidad 15, `max_features=0.7`, `min_samples_leaf=1`,

`class_weight="balanced_subsample"`) logró un macro-recall ≈ 0.51 (por encima del 0.24 del RF base) y un accuracy respetable del 79 %.

- b. **Por qué profundizar:** demuestra que, con un ajuste cuidadoso de profundidad, número de árboles y selección de características, los bosques aleatorios pueden repartir mucho mejor su poder predictivo entre todas las categorías. Afinar `min_samples_split`, `max_samples` o explorar `ExtraTrees` y `feature bagging` podría elevar aún más su recall en minorías sin caer drásticamente en precisión global.